

Task 2

EDA

By 白宸宇

Data

	原始資料		分類後資料	
	train_data_feeds.csv	train_data_ads.csv	potential_customers.csv	non_potential_customers.csv
欄位數	28 (u_userid)	35 (user_id)	28 (u_userid)	28 (u_userid)
資料筆數	3,227,732	7,675,517	2,475,843	751,889
Unique Value	180,123	65,297	65,297	114,826
說明	顧客看到廣告行為的資料	有點擊廣告的顧客資料 Ads中的所有資料都是潛在客戶 其中由65,297個客戶貢獻了7,675,517筆數據	feeds.csv中user_id同時出現在feeds與ads中的各比資料	feeds.csv中user_id僅出現在feeds中的各比資料

#	Column	Dtype
0	u_userId	int64
1	u_phonePrice	int64
2	u_browserLifeCycle	int64
3	u_browserMode	int64
4	u_feedLifeCycle	int64
5	u_refreshTimes	int64
6	u_newsCatInterests	object
7	u_newsCatDislike	object
8	u_newsCatInterestsST	object
9	u_click_ca2_news	object
10	i_docId	object
11	i_s_sourceId	object
12	i_regionEntity	int64
13	i_cat	int64
14	i_entities	object
15	i_dislikeTimes	int64
16	i_upTimes	int64
17	i_dtype	int64
18	e_ch	int64
19	e_m	int64
20	e_po	int64
21	e_pl	int64
22	e_rn	int64
23	e_section	int64
24	label	int64
25	cillabel	int64
26	pro	int64

變數摘要

經過觀察後發現object的欄位大多屬於一串序號，無法進行分析

因此將object類別的欄位Drop掉

#	Column	Dtype
0	u_userId	int64
1	u_phonePrice	int64
2	u_browserLifeCycle	int64
3	u_browserMode	int64
4	u_feedLifeCycle	int64
5	u_refreshTimes	int64
6	i_regionEntity	int64
7	i_cat	int64
8	i_dislikeTimes	int64
9	i_upTimes	int64
10	i_dtype	int64
11	e_ch	int64
12	e_m	int64
13	e_po	int64
14	e_pl	int64
15	e_rn	int64
16	e_section	int64
17	e_et	int64
18	label	int64
19	cillabel	int64
20	pro	int64

Potential Customers

u_userId	0
u_phonePrice	0
u_browserLifeCycle	0
u_browserMode	0
u_feedLifeCycle	0
u_refreshTimes	0
u_newsCatInterests	0
u_newsCatDislike	0
u_newsCatInterestsST	0
u_click_ca2_news	0
i_docId	0
i_s_sourceId	0
i_regionEntity	0
i_cat	0
i_entities	81474
i_dislikeTimes	0
i_upTimes	0
i_dtype	0
e_ch	0
e_m	0
e_po	0
e_pl	0
e_rn	0
e_section	0
e_et	0
label	0
cillabel	0
pro	0
dtype: int64	

觀察缺失值

僅i_entities有缺失值,

但由於屬於Object物件, 故不做處理

Non-Potential Customers

u_userId	0
u_phonePrice	0
u_browserLifeCycle	0
u_browserMode	0
u_feedLifeCycle	0
u_refreshTimes	0
u_newsCatInterests	0
u_newsCatDislike	0
u_newsCatInterestsST	0
u_click_ca2_news	0
i_docId	0
i_s_sourceId	0
i_regionEntity	0
i_cat	0
i_entities	22644
i_dislikeTimes	0
i_upTimes	0
i_dtype	0
e_ch	0
e_m	0
e_po	0
e_pl	0
e_rn	0
e_section	0
e_et	0
label	0
cillabel	0
pro	0
dtype: int64	

Variable Definition

			潛在客戶	非潛在客戶
變數名稱	定義	類型	可能值	
u_userId	使用者的ID	離散	65297	114826
u_phonePrice	使用者裝置的價格	離散	7	7
u_browserLifeCycle	瀏覽器上的使用者參與度	離散	8	8
u_browserMode	瀏覽器服務類型	離散	8	8
u_feedLifeCycle	用戶對新動態(feeds)的參與度	離散	8	8
u_refreshTimes	每天有效新動態(feeds)更新的平均數量。	離散	10	10
i_regionEntity	文章地域詞的ID	離散	374	364
i_cat	文章類別的ID	離散	208	207
i_dislikeTimes	文章負面反饋數	離散	10	10
i_upTimes	文章點讚數	離散	10	10

			潛在客戶	非潛在客戶
變數名稱	定義	類別	可能值	
i_dtype	文章展現形式	離散	5	5
e_ch	頻道	離散	19	19
e_m	事件來源設備機型	離散	256	262
e_po	第幾位	離散	27	27
e_pl	拜訪地	離散	3011	3089
e_rn	第幾刷	離散	99	99
e_section	訊息場景類型	離散	2	2
e_et	時間戳	離散	3653	3561
label	是否點擊	離散	2 (-1, 1)	2
cillabel	是否點讚	離散	2 (-1, 1)	2
pro	文章瀏覽進度	離散	82	35

1.分類後資料 EDA

基本統計量

Potential Customers

	count	mean	std	min	25%	50%	75%	max
u_userId	2475843.00	193415.57	54080.85	100002.00	146464.00	193505.00	240112.00	287180.00
u_phonePrice	2475843.00	13.28	2.15	10.00	11.00	14.00	15.00	16.00
u_browserLifeCycle	2475843.00	16.65	1.18	10.00	17.00	17.00	17.00	17.00
u_browserMode	2475843.00	13.39	1.58	10.00	13.00	14.00	14.00	17.00
u_feedLifeCycle	2475843.00	16.41	1.58	10.00	17.00	17.00	17.00	17.00
u_refreshTimes	2475843.00	5.52	3.11	0.00	4.00	6.00	9.00	9.00
i_regionEntity	2475843.00	460.79	875.97	0.00	0.00	0.00	476.00	3187.00
i_cat	2475843.00	112.91	63.85	0.00	65.00	105.00	169.00	220.00
i_dislikeTimes	2475843.00	2.09	2.95	0.00	0.00	0.00	4.00	9.00
i_upTimes	2475843.00	4.03	3.75	0.00	0.00	4.00	8.00	9.00
i_dtype	2475843.00	11.84	1.16	10.00	11.00	11.00	13.00	14.00
e_ch	2475843.00	17.89	3.37	1.00	19.00	19.00	19.00	20.00
e_m	2475843.00	833.57	426.11	14.00	508.00	842.00	1205.00	1483.00
e_po	2475843.00	7.82	4.28	1.00	6.00	7.00	10.00	27.00
e_pl	2475843.00	1630.85	854.42	0.00	888.00	1674.00	2314.00	3189.00
e_rm	2475843.00	3.18	5.04	1.00	1.00	1.00	3.00	99.00
e_section	2475843.00	0.26	0.44	0.00	0.00	0.00	1.00	1.00
e_et	2475843.00	202206061153.30	20009.18	202206030011.00	202206041926.00	202206061324.00	202206080921.00	202206092329.00
label	2475843.00	-0.79	0.62	-1.00	-1.00	-1.00	-1.00	1.00
cillabel	2475843.00	-1.00	0.03	-1.00	-1.00	-1.00	-1.00	1.00
pro	2475843.00	7.74	25.21	0.00	0.00	0.00	0.00	100.00

基本統計量

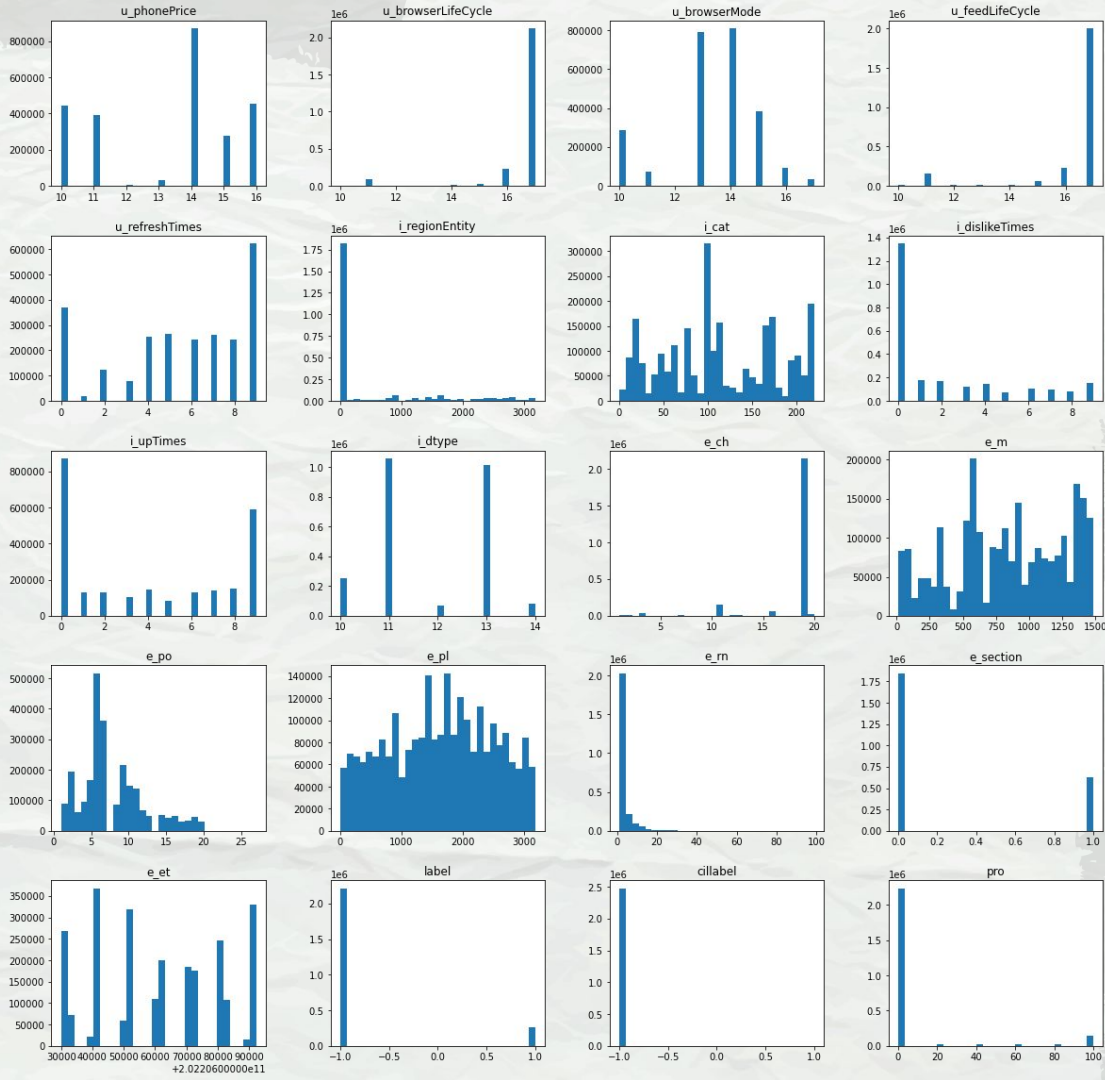
Non-Potential Customers

	count	mean	std	min	25%	50%	75%	max
u_userId	751889.00	193523.28	54193.89	100001.00	146746.00	193445.00	240599.00	287184.00
u_phonePrice	751889.00	13.29	2.14	10.00	11.00	14.00	15.00	16.00
u_browserLifeCycle	751889.00	15.81	2.18	10.00	16.00	17.00	17.00	17.00
u_browserMode	751889.00	13.32	1.60	10.00	13.00	14.00	14.00	17.00
u_feedLifeCycle	751889.00	14.93	2.50	10.00	13.00	16.00	17.00	17.00
u_refreshTimes	751889.00	2.44	2.96	0.00	0.00	0.00	5.00	9.00
i_regionEntity	751889.00	529.39	929.28	0.00	0.00	0.00	879.00	3187.00
i_cat	751889.00	115.17	62.98	0.00	65.00	109.00	168.00	220.00
i_dislikeTimes	751889.00	2.70	3.26	0.00	0.00	1.00	5.00	9.00
i_upTimes	751889.00	5.26	3.79	0.00	1.00	7.00	9.00	9.00
i_dtype	751889.00	11.72	1.17	10.00	11.00	11.00	13.00	14.00
e_ch	751889.00	18.26	2.88	1.00	19.00	19.00	19.00	20.00
e_m	751889.00	842.76	422.80	14.00	565.00	847.00	1205.00	1483.00
e_po	751889.00	7.74	3.84	1.00	6.00	7.00	9.00	27.00
e_pl	751889.00	1615.61	863.49	0.00	881.00	1667.00	2323.00	3189.00
e_rn	751889.00	2.34	3.89	1.00	1.00	1.00	2.00	99.00
e_section	751889.00	0.42	0.49	0.00	0.00	0.00	1.00	1.00
e_et	751889.00	202206060608.63	19902.27	202206030013.00	202206041827.00	202206061022.00	202206080819.00	202206092329.00
label	751889.00	-0.86	0.51	-1.00	-1.00	-1.00	-1.00	1.00
cillabel	751889.00	-1.00	0.03	-1.00	-1.00	-1.00	-1.00	1.00
pro	751889.00	5.07	20.73	0.00	0.00	0.00	0.00	100.00

直方圖

觀察類別型各欄位值的分佈

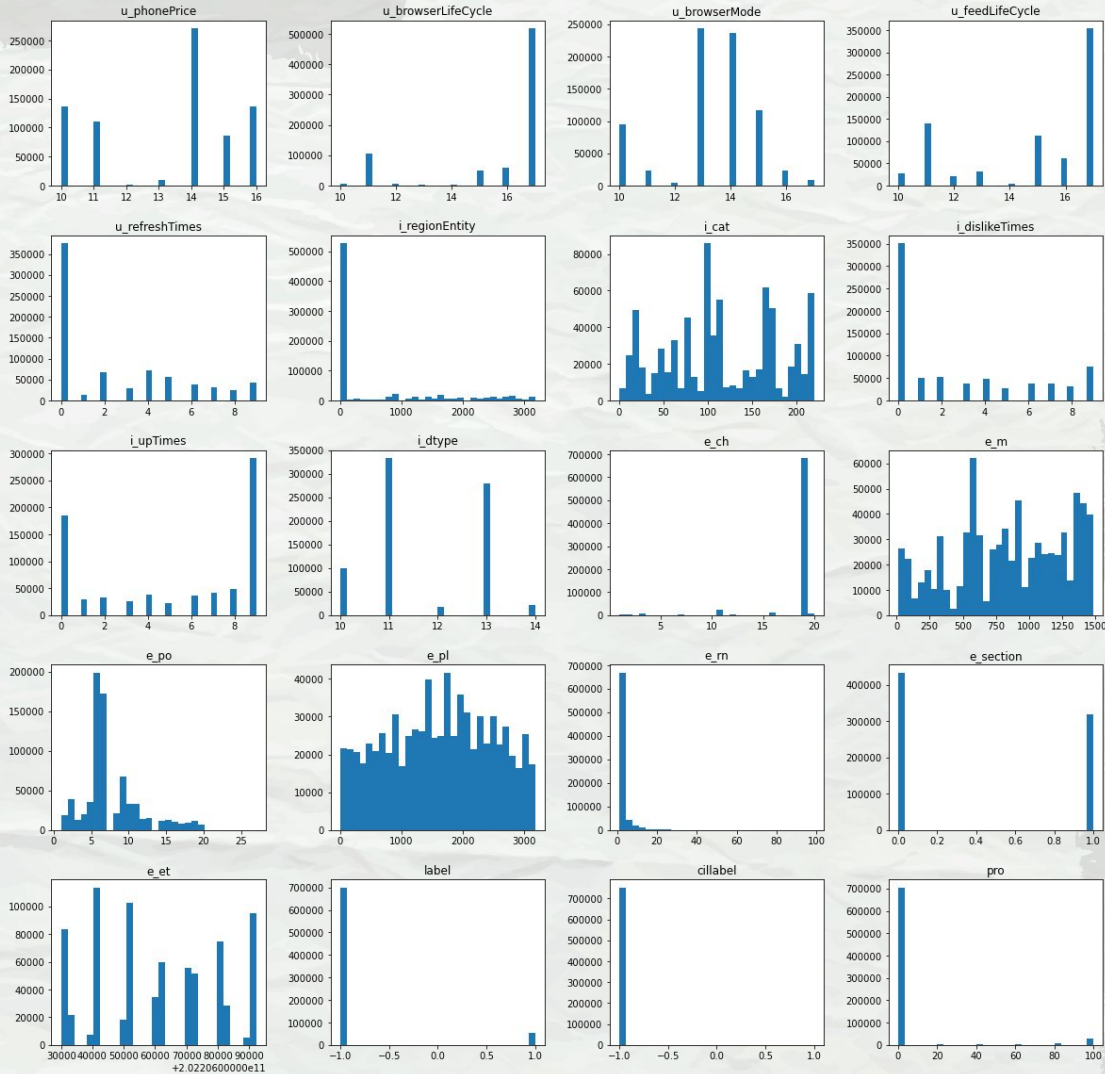
Potential Customers



直方圖

觀察類別型各欄位值的分佈


Non-Potential Customers



相關係數熱點圖

觀察個欄位之間的相關係數


Potential Customers



相關係數熱點圖

觀察個欄位之間的相關係數

Non-Potential Customers




圓餅圖

觀察點擊的比率


潛在客戶

Proportion of Label



非潛在客戶

Proportion of Label



2.ads.csv之EDA

變數摘要

#	Column	Dtype
0	log_id	int64
1	label	int64
2	user_id	int64
3	age	int64
4	gender	int64
5	residence	int64
6	city	int64
7	city_rank	int64
8	series_dev	int64
9	series_group	int64
10	emui_dev	int64
11	device_name	int64
12	device_size	int64
13	net_type	int64
14	task_id	int64
15	adv_id	int64
16	creat_type_cd	int64
17	adv_prim_id	int64
18	inter_type_cd	int64
19	slot_id	int64
20	site_id	int64
21	spread_app_id	int64
22	hispace_app_tags	int64
23	app_second_class	int64
24	app_score	float64
25	ad_click_list_v001	object
26	ad_click_list_v002	object
27	ad_click_list_v003	object

28	ad_close_list_v001	object
29	ad_close_list_v002	object
30	ad_close_list_v003	object
31	pt_d	int64
32	u_newsCatInterestsST	object
33	u_refreshTimes	int64
34	u_feedLifeCycle	int64

經過觀察後發現object的欄位大多屬於一串序號，無法進行分析

因此將object類別的欄位Drop掉

#	Column	Dtype
0	log_id	int64
1	label	int64
2	user_id	int64
3	age	int64
4	gender	int64
5	residence	int64
6	city	int64
7	city_rank	int64
8	series_dev	int64
9	series_group	int64
10	emui_dev	int64
11	device_name	int64
12	device_size	int64
13	net_type	int64
14	task_id	int64
15	adv_id	int64
16	creat_type_cd	int64
17	adv_prim_id	int64
18	inter_type_cd	int64
19	slot_id	int64
20	site_id	int64
21	spread_app_id	int64
22	hispace_app_tags	int64
23	app_second_class	int64
24	app_score	float64
25	pt_d	int64
26	u_refreshTimes	int64
27	u_feedLifeCycle	int64

Variable Definition

變數名稱	定義	類型	可能值
label	使用者的ID	離散	2 (0,1)
user_id	使用者的ID	離散	65297
age	年紀	離散	8
gender	性別	離散	3
residence	永久居住地ID	離散	35
city	居住城市ID	離散	341
city_rank	居住城市等級	離散	4
series_dev	設備系列	離散	27
series_group	設備系列分組	離散	7
emui_dev	emui版本號碼	離散	27

變數名稱	定義	類型	可能值
device_name	使用者手機機型	離散	256
device_size	使用者手機尺寸	離散	1547
net_type	行為時的網路狀態	離散	6
task_id	廣告任務ID	離散	11209
adv_id	廣告任務對應的素材ID	離散	12615
creat_type_cd	素材的創意類型ID	離散	9
adv_prim_id	廣告任務對應的廣告主ID	離散	545
inter_type_cd	廣告任務對應的素材的交互類型	離散	4
slot_id	廣告位ID	離散	60
site_id	媒體ID	離散	1
spread_app_id	投放廣告對應的App ID	離散	116

變數名稱	定義	類型	可能值
hispace_app_tags	廣告任務對應的App標籤	離散	43
app_second_class	廣告任務對應的App的二級分類	離散	20
app_score	App得分	離散	3
pt_d	時間戳	離散	5436
u_refreshTimes	每天有效新動態(feeds)更新的平均數量。	離散	10
u_feedLifeCycle	用戶對新動態(feeds)的參與度	離散	8

直方圖

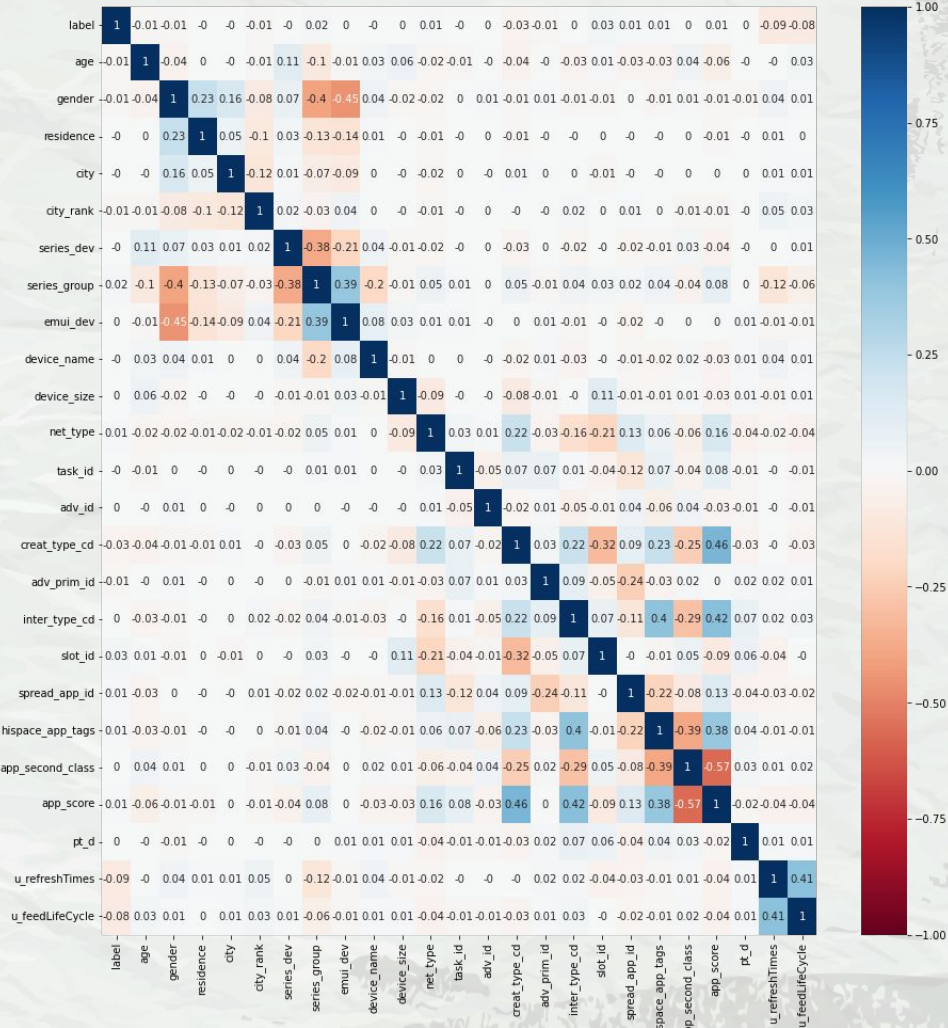
觀察類別型各欄位值的分佈

屬於Id的欄位觀察沒有意義



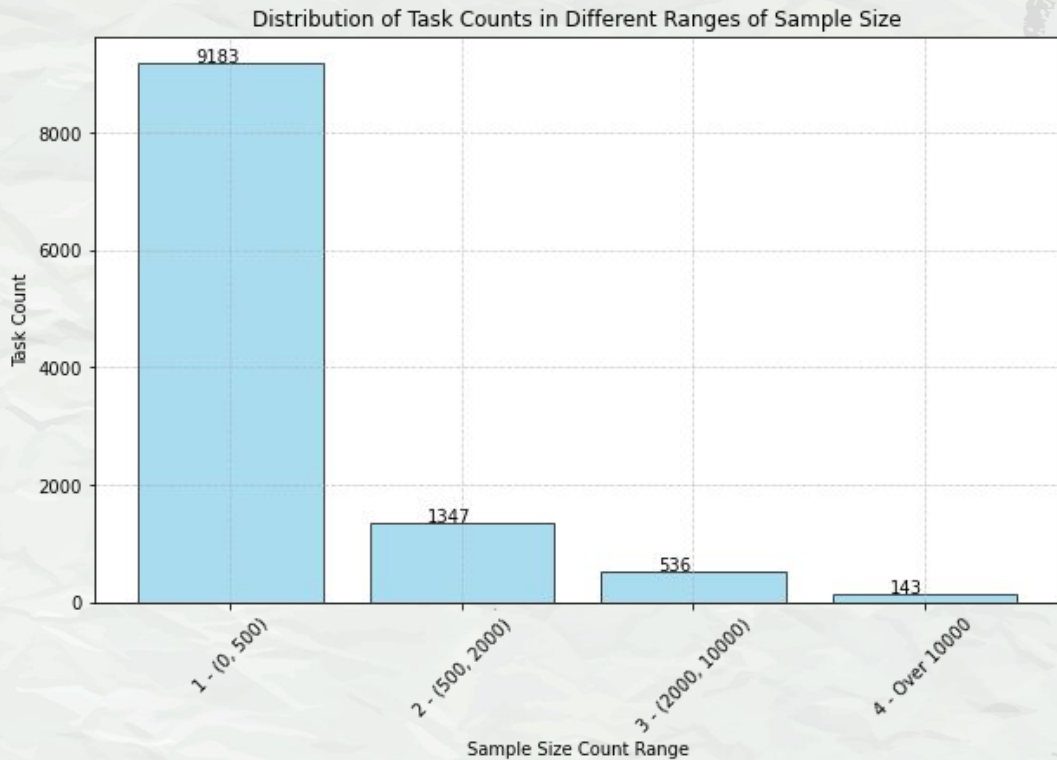
相關係數熱點圖

觀察個欄位之間的相關係數



Task counts

觀察task_id中的數量分佈



Thanks for watching